

Laboratorium 5

Pandas - biblioteka pythona do analizy danych, oparta na bibliotece *NumPy*. Pandas, umożliwia tworzenie tzw. DataFrame na kilka sposobów. Między innymi na podstawie listy, słownika czy też plików csv, xls, json.

ZADANIA

Skorzystaj z danych z pliku lab5Data10per.csv. Dane te pochodzą ze zgłoszeń do władz Nowego Jorku za pośrednictwem numeru 3-1-1: <https://nycopendata.socrata.com/Social-Services/311-Service-Requests-from-2010-to-Present/erm2-nwe9>

Na podstawie pliku CSV znajdź:

1. 10 najczęściej zgłaszanych skarg ('Complaint Type'); - 1pkt
2. 3 najczęściej zgłaszane skargi ('Complaint Type') w każdej dzielnicy ('Borough'); - 1pkt
 - zrób listę wszystkich dzielnic;
 - po wszystkich dzielnicach:
 - wytnij dane z tabeli dla danej dzielnicy;
 - weź 10 najczęściej składanych skarg.
3. 3 urzędy ('Agency Name'), do których najczęściej zgłaszano skargi (z wymienieniem 3 najpopularniejszych skarg dla każdego urzędu); - 1pkt
4. 4 lokalizacje ('Location Type'), w których najczęściej zgłaszano skargi (z wymienieniem 2 najpopularniejszych skarg dla każdej lokalizacji); - 1pkt
5. Procentowy udział zgłoszeń o różnych statusach realizacji ('Status'): 'in Progress', 'Closed', 'Open', 'Assigned'. Przedstaw dane w postaci wykresu kołowego. - 1pkt

Zmierz czasy wykonania "zapytań".

PRZYDATNE INFORMACJE

Do mierzenia czasu wykorzystaj np. metodę `default_timer()` z pakietu `timeit`.

Tworzenie DataFrame na bazie pliku CSV:

```
df = pd.read_csv(filePath)
# pobranie wybranych kolumn
df = pd.read_csv(filePath, usecols=['Agency Name', 'Complaint Type', ??])
```

Wyświetlenie wybranych wierszy i/lub kolumn:

```
df[:3] # pierwsze 3 wiersze
df[['Agency Name', 'Complaint Type']] # wybrane kolumny
df.loc[:3,['Agency Name', 'Complaint Type', 'Borough']]
```

Do zliczenia występowania danych wartości w wybranej kolumnie możemy użyć:

```
complaintType = df['Complaint Type'].value_counts()  
# uzyskane wyniki będą posortowane od najpopularniejszych
```

Aby przekształcić uzyskane wyniki do listy możemy użyć metody:

```
index.tolist()
```

Inne przydatne metody:

dropna() - usuwa z DataFrame wszystkie wiersze z wartościami NULL

unique() - zwraca niepowtarzalne wiersze (nie sortuje)

str.contains() - sprawdza czy występuje dana fraza; jeśli nie to możemy ją uzupełnić ustawiając dodatkowo parametr "na"; np. na=False

<https://pandas.pydata.org/pandas-docs/stable/reference/frame.html>

https://www.w3schools.com/python/pandas/pandas_ref_dataframe.asp